Feature Engineering e Feature Store

Pipeline de Dados: Integração, Qualidade e Automação

Lucas Zegrine Duarte
1327493@pucminas.edu.br
lucas.zegrine@gmail.com
Aluno - 1327493
PUC Minas
Pós Graduação Engenharia de Inteligência Artificial e MLOps
Belo Horizonte, Minas Gerais, Brasil

KEYWORDS

feature engineering, normalização, padronização, seleção de atributos

1 INTRODUÇÃO

Feature Engineering é o processo de criar, transformar, selecionar e representar variáveis a partir dos dados brutos, de modo que um modelo de aprendizado de máquina receba entradas numéricas, comparáveis e relevantes para o problema. Os dados originais reúnem categorias, escalas distintas e relações que não aparecem de forma direta nas colunas iniciais. As técnicas a seguir organizam essas transformações.

- **One-Hot Encoding.** Representa uma variável categórica sem ordem natural por um conjunto de colunas binárias, uma para cada categoria. Cada observação recebe o valor 1 na coluna da categoria correspondente e 0 nas demais. Cada coluna identifica uma categoria, o que torna a representação interpretável e compatível com modelos que exigem entradas numéricas, e as categorias permanecem independentes. Com muitas categorias, surge uma coluna por valor distinto: a matriz fica esparsa, o uso de memória cresce e o treinamento de alguns modelos fica mais custoso. Categorias que aparecem só em produção, ausentes no treinamento, pedem tratamento explícito, como o oferecido pelo `OneHotEncoder` do scikit-learn.
- **Ordinal Encoding.** Representa uma variável categórica ordenada por números inteiros que preservam essa hierarquia. A posição numérica de cada código corresponde à posição relativa da categoria.
- **Normalização.** Reescala cada variável para um intervalo fixo, em geral de 0 a 1, pela transformação Min-Max. Variáveis medidas em unidades ou amplitudes diferentes passam a ocupar a mesma faixa de valores.
- **Padronização.** Recentra cada variável na média zero e a reescala para desvio padrão unitário, pela transformação Z-score. Cada observação passa a ser descrita pelo número de desvios em relação à média da própria variável.
- **Feature Selection.** Escolhe o subconjunto de variáveis mais associadas ao objetivo do modelo. A seleção reduz ruído, redundância e a quantidade de entradas apresentadas ao algoritmo. Os procedimentos se organizam em três categorias:
  - **Filter Methods.** Avaliam cada variável por uma medida estatística calculada sobre os dados, antes de qualquer treinamento. Correlação, informação mútua, teste qui-quadrado e ANOVA são exemplos. O custo permanece baixo e o critério independe do algoritmo usado depois. Cada variável é julgada isoladamente, então interações entre elas ficam fora da seleção.
  - **Wrapper Methods.** Percorrem subconjuntos de variáveis e medem cada subconjunto pelo desempenho de um modelo treinado nele. Seleção *forward*, eliminação *backward* e eliminação recursiva de features (RFE) são exemplos. O subconjunto fica ligado ao modelo da busca e reflete combinações entre variáveis. O custo cresce com o número de subconjuntos avaliados.
  - **Embedded Methods.** Incorporam a seleção ao próprio treinamento. A regularização L1, como no Lasso, reduz a zero os coeficientes de variáveis pouco úteis, e modelos baseados em árvores atribuem importância às variáveis ao construir as divisões. O critério de seleção e o modelo ficam no mesmo ajuste, com custo próximo ao de um único treinamento.
- **Polynomial Features.** Gera novas variáveis a partir de potências e produtos das variáveis originais. Essas combinações permitem que um modelo linear represente relações curvas e interações entre as entradas.

Este relatório aplica essas técnicas às questões da atividade. Cada questão reúne o enunciado, o procedimento adotado e o resultado obtido.

2 QUESTÃO 1

2.1 Enunciado

Um e-commerce possui várias categorias de produtos descritas no conjunto de dados a seguir:

```
{
    'Produto': [
        'Eletrônicos',
        'Roupas',
        'Eletrodomésticos',
        'Eletrônicos',
        'Livros',
        'Roupas',
```

In: Otimização de Sistemas (PUC MG). Belo Horizonte/MG, Brazil. Porto Alegre: Brazilian Computer Society, 2026.
© 2026 SBC – Brazilian Computing Society.

```
        'Livros'
    ]
}
```

Aplique a codificação one-hot para representar as categorias de produtos em formato numérico.

2.2 Solução

A coluna `Produto` tem quatro categorias sem ordem: Eletrodomésticos, Eletrônicos, Livros e Roupas. O script monta o `DataFrame` das sete observações e aplica `pandas.get_dummies` com `dtype=int`. Cada categoria vira uma coluna binária (`Produto_<categoria>`): 1 na categoria da linha e 0 nas demais. Cada linha fica com um único 1.

2.3 Resultado

A Tabela 1 mostra a matriz. A coluna `Produto` fica ao lado dos indicadores. Os cabeçalhos omitem o prefixo `Produto_`. O arquivo `scripts/results/q1.csv` guarda as quatro colunas binárias.

Tabela 1: Codificação one-hot das categorias de produto.

Produto	Eletro-domésticos	Eletrô-nicos	Livros	Roupas
Eletrônicos	0	1	0	0
Roupas	0	0	0	1
Eletrodomésticos	1	0	0	0
Eletrônicos	0	1	0	0
Livros	0	0	1	0
Roupas	0	0	0	1
Livros	0	0	1	0

3 QUESTÃO 2

3.1 Enunciado

Considere o seguinte conjunto de dados:

```
data = {
    'Tamanho': [150, 120, 180, 130, 160],
    'Quartos': [3, 2, 4, 3, 4],
    'Preço': [200000, 180000, 250000, 190000, 220000],
    'Localização': [
        'Norte', 'Leste', 'Oeste', 'Sul', 'Centro'
    ]
}
```

Aplique a técnica de seleção de features para selecionar as features mais relevantes para o negócio.

3.2 Solução

O alvo é `Preço`. As entradas são `Tamanho`, `Quartos` e `Localização`. `Localização` entra como one-hot. A seleção usa `SelectKBest` com `f_regression` e $k = 2$: a estatística F da regressão linear de cada feature com o preço. As duas de maior F são mantidas.

3.3 Resultado

Na amostra, `Tamanho` ($F = 54{,}56$) e `Quartos` ($F = 10{,}62$) apresentaram os maiores F-scores e foram selecionadas pelo `SelectKBest`. `Localização` foi codificada em indicadores one-hot e avaliada, mas não entrou entre as duas primeiras. A Tabela 2 traz o ranking completo.

Tabela 2: Ranking das features pela estatística F em relação ao preço.

Feature	F	p	Selecionada
Tamanho	54,56	0,005	Sim
Quartos	10,62	0,047	Sim
Localização_Oeste	7,56	0,071	Não
Localização_Leste	1,40	0,322	Não
Localização_Sul	0,45	0,549	Não
Localização_Centro	0,19	0,695	Não
Localização_Norte	0,08	0,796	Não

4 QUESTÃO 3

4.1 Enunciado

Considere o seguinte conjunto de dados:

```
data = {
    'Matemática': [85, 92, 78, 96, 88],
    'Português': [7, 5, 8, 9, 6]
}
```

É conhecido que as notas de Matemática variam de 0 a 100, enquanto as notas de Português variam de 0 a 10. Aplique a normalização Min-Max e a padronização Z-Score para as notas em ambas as disciplinas, de modo que elas estejam na mesma escala e distribuição.

4.2 Solução

As notas de Matemática pertencem à faixa de 0 a 100 e as de Português à faixa de 0 a 10. Os valores brutos, por isso, não compartilham escala. A normalização Min-Max da aula reescala cada coluna para o intervalo $[0, 1]$:

$$z_{\text{norm}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}}.$$

$x_{\min}$ e $x_{\max}$ são o mínimo e o máximo observados na própria coluna, como no exemplo numérico da aula. A padronização Z-score coloca cada coluna com média zero e desvio padrão unitário:

$$z = \frac{x - \mu}{\sigma}.$$

O script ajusta `MinMaxScaler` e `StandardScaler`. O desvio é o populacional, o mesmo do exemplo da aula. Em Matemática, o mínimo é 78, o máximo é 96, a média é 87,8 e o desvio é 6,145. Em Português, o mínimo é 5, o máximo é 9, a média é 7 e o desvio é 1,414.

4.3 Resultado

Depois das duas transformações, as disciplinas passam a ocupar o intervalo $[0, 1]$ e, na padronização, a mesma distribuição (média 0 e desvio 1). A Tabela 3 reúne os valores. O arquivo `scripts/results/q3_escalas.csv` guarda a tabela.

Tabela 3: Notas originais, normalização Min-Max e padronização Z-score.

Mat. orig.	Port. orig.	Mat. Min-Max	Port. Min-Max	Mat. Z	Port. Z
85	7	0,389	0,500	−0,456	0,000
92	5	0,778	0,000	0,683	−1,414
78	8	0,000	0,750	−1,595	0,707
96	9	1,000	1,000	1,334	1,414
88	6	0,556	0,250	0,033	−0,707

5 QUESTÃO 4

5.1 Enunciado

Considere o seguinte conjunto de dados:

```
data = {
    'Nota_Matemática': [8, 7, 9, 6, 8],
    'Nota_Português': [7, 6, 8, 5, 7],
    'Satisfação_Curso': [4, 3, 5, 2, 4]
}
```

Aplique uma técnica de transformação não linear para criar novas features que capturem as relações entre as notas e a satisfação do curso.

5.2 Solução

A aula descreve a transformação não linear como uma operação cujo resultado não é proporcional ao valor original e que torna visível uma relação que as colunas brutas não mostram. Polynomial Features de grau 2 cumpre esse papel: para cada observação, o script gera o quadrado de cada variável e o produto de cada par. Os produtos da nota de Matemática e da nota de Português com a satisfação do curso ligam o desempenho à satisfação. Os quadrados introduzem a curvatura de cada variável. O termo constante fica de fora (`include_bias=False`).

5.3 Resultado

A Tabela 4 mostra as colunas originais e as seis features novas. NM é a nota de Matemática, NP a de Português e Sat. a satisfação do curso. As duas primeiras linhas e a última repetem o mesmo perfil de notas e, por isso, as mesmas features. O arquivo `scripts/results/q4_polynomial.csv` guarda a matriz.

6 QUESTÃO 5

6.1 Enunciado

Considere o seguinte conjunto de dados:

```
data = {
    'Idade': [28, 35, 45, 22, 31],
    'Produtos_Comprados': [5, 9, 7, 3, 6]
}
```

Aplique uma técnica de transformação linear para criar novas features que correlacionem a Idade com Produtos_Comprados.

6.2 Solução

A aula lista a criação de features de interação entre as transformações lineares. A operação é o produto de duas colunas, no mesmo formato de `valor_total = preço × quantidade`, e serve para correlacionar dois atributos numa coluna só. A feature nova é `Idade_x_Produtos` = Idade × Produtos comprados. A correlação de Pearson entre as colunas originais resume a associação linear que esse produto carrega.

6.3 Resultado

A correlação de Pearson entre idade e produtos comprados é 0,729: na amostra, idade maior acompanha mais compras. A Tabela 5 traz o produto em cada linha. O arquivo `scripts/results/q5_interacao.csv` guarda a tabela.

Tabela 5: Feature de interação entre idade e produtos comprados.

Idade	Produtos comprados	Idade × produtos
28	5	140
35	9	315
45	7	315
22	3	66
31	6	186

7 QUESTÃO 6

7.1 Enunciado

Considere o conjunto de dados `transacoes_bancarias.csv`, disponibilizado no Canvas:

- Aplique uma técnica de Feature Engineering para descobrir correlações entre Sexo e tipo de produto comprado.
- Aplique uma técnica de Feature Engineering para identificar qual dia da semana (domingo a sábado) ocorre mais compras.
- Aplique uma técnica de Feature Engineering para dimensionar os valores dos produtos por estado numa escala de 0 a 1.

7.2 Sexo e tipo de produto

`Sexo` e `Produto` são categóricos. O script codifica `Produto` com `get_dummies`, como na Questão 1, e `Sexo` como indicador (Feminino = 1, Masculino = 0). A correlação de Pearson entre esse indicador e cada produto mede a associação. O teste qui-quadrado da tabela de contingência, um dos *filter methods* da aula, avalia se as duas categorias são independentes. O V de Cramér, calculado a partir desse qui-quadrado, resume a intensidade entre 0 e 1.

Nas 1.000 transações, o qui-quadrado é 12,13, com 19 graus de liberdade e $p = 0{,}880$. O V de Cramér é 0,110. A associação é fraca. A maior correlação absoluta é 0,045 (cafeteira, mais frequente entre mulheres) e todos os p por produto ficam acima de 0,16. A Tabela 6 lista os vinte produtos. O arquivo `scripts/results/q6_sexo_produto.csv` guarda a tabela.

7.3 Dia da semana

A aula extrai o dia da semana de uma coluna de data e agrega contagens por grupo. `Data` é convertida para datetime e cada compra recebe o dia, de domingo a sábado. A contagem por dia indica onde as compras se concentram.

Tabela 4: Features polinomiais de grau 2 para notas e satisfação.

NM	NP	Sat.	NM^2	NM×NP	NM×Sat.	NP^2	NP×Sat.	$Sat.^2$
8	7	4	64	56	32	49	28	16
7	6	3	49	42	21	36	18	9
9	8	5	81	72	45	64	40	25
6	5	2	36	30	12	25	10	4
8	7	4	64	56	32	49	28	16

Tabela 6: Associação entre sexo e tipo de produto. Correlação com o indicador Feminino = 1.

Produto	Feminino	Masculino	r	p
Cafeteira	31	21	0,045	0,166
Cadeira de escritório	32	22	0,044	0,174
Smartphone	21	30	−0,041	0,208
Notebook	27	20	0,033	0,307
Máquina de lavar	28	21	0,032	0,317
Fogão	17	23	−0,031	0,343
Console	20	26	−0,029	0,376
Aspirador de pó	20	25	−0,024	0,456
Micro-ondas	22	27	−0,023	0,475
Liquidificador	20	24	−0,020	0,546
Tablet	26	22	0,019	0,564
Geladeira	28	24	0,018	0,579
Laptop	27	31	−0,017	0,599
Sofá	26	23	0,014	0,668
Ventilador	28	25	0,013	0,680
Cama de casal	17	19	−0,011	0,739
Televisão	25	27	−0,009	0,782
Secador de cabelo	26	28	−0,009	0,785
Computador	30	32	−0,008	0,799
Máquina de café	29	30	−0,004	0,896

Sábado reúne o maior volume: 163 compras, 16,3% do total. Segunda-feira reúne o menor, 110. A Tabela 7 traz a semana inteira. O arquivo `scripts/results/q6_dia_semana.csv` guarda a contagem.

Tabela 7: Compras por dia da semana.

Dia	Compras	Proporção
Domingo	131	13,1%
Segunda-feira	110	11,0%
Terça-feira	147	14,7%
Quarta-feira	157	15,7%
Quinta-feira	144	14,4%
Sexta-feira	148	14,8%
Sábado	163	16,3%

7.4 Valor por estado

A escala de 0 a 1 é a normalização Min-Max da aula, aplicada dentro de cada estado. O campo `Estado` chega como o par (UF, nome) e é separado antes do agrupamento. Em cada UF, o menor `Valor` vai a 0 e o maior vai a 1:

$$z_{\text{UF}} = \frac{x - x_{\min,\text{UF}}}{x_{\max,\text{UF}} - x_{\min,\text{UF}}}.$$

Os 27 estados fecham o intervalo: o normalizado mínimo é 0 e o máximo é 1 em todos eles. A Tabela 8 mostra, para três estados, o extremo inferior, um valor intermediário e o extremo superior já na escala nova. A Tabela 9 lista a faixa original de cada estado. Os arquivos `scripts/results/q6_valor_estado.csv` e `scripts/results/q6_valor_norm.csv` guardam o resumo e as 1.000 linhas transformadas.

Tabela 8: Amostra da escala 0 a 1 do valor, por estado.

UF	Produto	Valor	Escala
AC	Liquidificador	418,24	0,000
AC	Smartphone	5140,19	0,495
AC	Sofá	9961,79	1,000
MG	Sofá	1178,04	0,000
MG	Notebook	5310,23	0,490
MG	Console	9617,76	1,000
SP	Computador	957,21	0,000
SP	Laptop	6017,55	0,561
SP	Ventilador	9980,54	1,000

Tabela 9: Faixa de valor por estado antes da escala 0 a 1. Em todos, o normalizado vai de 0 a 1.

UF	Estado	*n*	Mínimo	Máximo
AC	Acre	40	418,24	9961,79
AL	Alagoas	27	619,77	9231,89
AM	Amazonas	42	286,91	9774,14
AP	Amapá	34	127,90	9220,49
BA	Bahia	37	57,47	9792,74
CE	Ceará	36	658,82	9593,56
DF	Distrito Federal	44	74,63	9975,50
ES	Espírito Santo	32	58,23	9562,80
GO	Goiás	39	339,72	9546,43
MA	Maranhão	40	427,39	9857,82
MG	Minas Gerais	39	1178,04	9617,76
MS	Mato Grosso do Sul	40	367,38	9961,28
MT	Mato Grosso	42	25,42	9872,53
PA	Pará	30	194,54	9970,01
PB	Paraíba	39	193,99	9896,82
PE	Pernambuco	23	328,53	9919,73
PI	Piauí	32	259,19	9680,84
PR	Paraná	36	474,38	9992,45
RJ	Rio de Janeiro	39	100,88	9874,21
RN	Rio Grande do Norte	36	169,31	9753,79
RO	Rondônia	49	258,74	9513,47
RR	Roraima	33	301,81	9778,12
RS	Rio Grande do Sul	39	261,08	9957,18
SC	Santa Catarina	29	620,77	9875,35
SE	Sergipe	41	71,92	9858,92
SP	São Paulo	39	957,21	9980,54
TO	Tocantins	43	474,47	9849,86